

Laporan Final Project
Analisis Pasar Kerja Data Science di Indonesia
Berbasis Big Data Pipeline dengan Apache PySpark

Mata Kuliah Analitik Big Data
Kelas Analitik Big Data - C

NIM	: 245150207111020
Nama	: Affan Abyarahman
Dosen	: Rizal Setya Perdana, S.Kom., M.Kom., Ph.D.
Institusi	: Departemen Teknik Informatika, Fakultas Ilmu Komputer
Universitas	: Universitas Brawijaya
Tahun	: 2026

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi yang pesat telah mendorong meningkatnya permintaan terhadap tenaga kerja di bidang ilmu data (Data Science) secara signifikan di Indonesia. Platform rekrutmen daring seperti JobStreet menjadi salah satu sumber data yang kaya akan informasi mengenai tren pasar kerja, kualifikasi yang dibutuhkan, serta distribusi geografis lowongan pekerjaan di berbagai sektor industri.

Dalam konteks mata kuliah Analitik Big Data, proyek ini memanfaatkan ekosistem Apache Spark melalui antarmuka PySpark untuk membangun pipeline analitik end-to-end. Pipeline ini mencakup seluruh tahapan siklus hidup big data, mulai dari pengumpulan data secara otomatis melalui web scraping, preprocessing, analisis eksploratif menggunakan Spark SQL, hingga penerapan algoritma machine learning tidak terawasi (unsupervised learning) berupa K-Means Clustering dari pustaka MLlib.

1.2 Rumusan Masalah

Proyek ini dirancang untuk menjawab pertanyaan-pertanyaan berikut:

1. Bagaimana distribusi geografis lowongan pekerjaan Data Science di Indonesia berdasarkan data JobStreet?
2. Apa saja jenis pekerjaan dan perusahaan yang paling aktif merekrut di bidang Data Science?
3. Bagaimana pola pengelompokan (clustering) lowongan pekerjaan berdasarkan kemiripan persyaratan (job requirements)?
4. Apa saja skills dan teknologi yang paling banyak diminta oleh perusahaan dalam lowongan Data Science?

1.3 Tujuan Proyek

Tujuan utama proyek ini adalah membangun sebuah pipeline analitik big data yang fungsional dan terdokumentasi dengan baik menggunakan Apache PySpark, serta menghasilkan insight yang bermakna mengenai kondisi pasar kerja Data Science di Indonesia. Secara khusus, proyek ini bertujuan untuk mendemonstrasikan penerapan Spark SQL untuk analisis eksploratif, TF-IDF untuk representasi fitur teks, serta K-Means Clustering dari MLlib untuk pengelompokan lowongan pekerjaan.

1.4 Ruang Lingkup

Aspek	Deskripsi
Sumber Data	Portal pekerjaan JobStreet Indonesia (id.jobstreet.com)
Kata Kunci	Data Science
Wilayah	Indonesia
Jumlah Data	150 baris lowongan pekerjaan
Periode Scraping	Maret 2026

Aspek	Deskripsi
Framework Utama	Apache PySpark 3.5.1
Algoritma ML	K-Means Clustering (MLlib) dengan k=4
Platform	Google Colaboratory

BAB 2

METODOLOGI

2.1 Arsitektur Pipeline

Pipeline analitik yang dibangun pada proyek ini mengikuti arsitektur linear yang terdiri dari sembilan tahapan berurutan. Setiap tahapan diimplementasikan sebagai sel notebook terpisah pada Google Colaboratory untuk memudahkan debugging dan dokumentasi.

Tahap	Sel	Deskripsi	Output
Environment Setup	Cell 1	Instalasi dependensi dan konfigurasi Java/PySpark	Lingkungan siap
SparkSession Init	Cell 2	Inisialisasi SparkSession dengan konfigurasi optimal	Session aktif
Data Ingestion	Cell 3	Pembacaan CSV dan inspeksi skema	Spark DataFrame
Data Cleaning	Cell 4	Normalisasi, handling null, feature engineering	DataFrame bersih
EDA (Spark SQL)	Cell 5	Analisis eksploratif dengan 5 query SQL	Tabel statistik
Visualisasi	Cell 6	5 chart dari hasil EDA	File PNG
K-Means Clustering	Cell 7	TF-IDF pipeline + MLlib K-Means	DataFrame cluster
Interpretasi Cluster	Cell 8	WordCloud per cluster + tabel ringkasan	File PNG + tabel
Pipeline Summary	Cell 9	Ringkasan hasil dan cleanup SparkSession	Laporan terminal

Tabel 2.1 Arsitektur Pipeline (9 Tahapan)

2.2 Pengumpulan Data (Web Scraping)

Data dikumpulkan secara otomatis menggunakan Selenium WebDriver dengan Google Chrome dalam mode headless. Pendekatan ini dipilih karena JobStreet menggunakan JavaScript rendering sehingga scraping sederhana berbasis HTTP request tidak dapat mengakses konten halaman secara penuh. Proses scraping dilakukan dalam dua tahap: pertama, mengekstrak ringkasan lowongan dari halaman hasil pencarian; kedua, mengunjungi setiap halaman detail lowongan secara individual untuk mengekstrak informasi yang lebih lengkap.

Untuk menghindari pemblokiran dari server, diterapkan delay antar request sebesar tiga detik menggunakan `time.sleep()`. Total lima halaman hasil pencarian diproses, menghasilkan 150 baris data mentah yang disimpan dalam format CSV.

Komponen	Detail
Browser Automation	Selenium WebDriver + Google Chrome headless
HTML Parser	BeautifulSoup4
Halaman Diproses	5 halaman hasil pencarian + 150 halaman detail
Delay Antar Request	3 detik (<code>time.sleep()</code>)
Format Output	CSV (<code>raw_dataset_jobstreet.csv</code>)

Komponen	Detail
Kendala	Beberapa atribut tidak tersedia di semua posting (education_req, experience_level)

Tabel 2.2 Komponen Web Scraping

2.3 Teknologi dan Pustaka

Teknologi	Versi	Fungsi
Apache PySpark	3.5.1	Framework utama pemrosesan big data
Spark SQL	Bawaan	Analisis eksploratif dan agregasi data
Spark MLlib	Bawaan	K-Means Clustering dan TF-IDF pipeline
Selenium	Terbaru	Otomasi pengambilan data dari web
BeautifulSoup4	Terbaru	Parsing HTML halaman JobStreet
matplotlib & seaborn	Terbaru	Visualisasi hasil analisis
WordCloud	Terbaru	Visualisasi frekuensi kata per cluster
Google Colaboratory	N/A	Platform eksekusi notebook berbasis cloud
OpenJDK	17.0.19	Runtime Java yang diperlukan PySpark

Tabel 2.3 Teknologi dan Pustaka

BAB 3

DATA DAN PREPROCESSING

3.1 Deskripsi Dataset Mentah

Dataset mentah yang dihasilkan dari proses web scraping terdiri dari 150 baris data dan 11 kolom atribut. Dataset ini mencerminkan kondisi lowongan pekerjaan dengan kata kunci 'Data Science' yang aktif di platform JobStreet Indonesia pada periode Maret 2026.

No.	Nama Atribut	Deskripsi	Null (setelah cleaning)	Kelengkapan
1	job_title	Judul posisi pekerjaan	0	100%
2	company_name	Nama perusahaan pemberi kerja	0	100%
3	location	Kota atau lokasi penempatan kerja	0	100%
4	job_type	Tipe pekerjaan (Full time, Kontrak, dll.)	0	100%
5	experience_level	Tingkat pengalaman yang dibutuhkan	95	36.7%
6	education_req	Persyaratan pendidikan minimum	150	0%
7	salary_range	Rentang gaji yang ditawarkan	115	23.3%*
8	job_requirements	Deskripsi kualifikasi dan persyaratan	0	100%
9	job_responsibilities	Tugas dan tanggung jawab posisi	115	23.3%
10	posted_date	Informasi waktu posting lowongan	0	100%
11	source_platform	Platform sumber data (JobStreet)	0	100%

Tabel 3.1 Deskripsi Dataset Mentah (11 Kolom, 150 Baris)

Catatan: salary_range terisi 100% secara teknis, namun 76.7% nilainya 'Disembunyikan'. Hanya 35 baris (23.3%) memiliki nilai numerik eksplisit. Null count dihitung setelah proses cleaning (Cell 4 Pipeline.ipynb).

3.2 Kondisi Data Mentah dan Limitasi

Terdapat beberapa kondisi pada dataset mentah yang perlu dipahami sebelum memasuki tahap analisis. Pertama, atribut education_req tidak berhasil diekstrak dari halaman detail JobStreet karena platform tersebut tidak memiliki struktur HTML yang konsisten untuk informasi pendidikan. Sebagian lowongan menyajikan persyaratan pendidikan sebagai bagian dari deskripsi bebas, sementara sebagian lainnya menggunakan heading terpisah. Kondisi ini menyebabkan 100% nilai atribut tersebut tidak tersedia.

Kedua, atribut experience_level hanya terisi pada 36.7% data karena informasi pengalaman juga tidak selalu disajikan secara eksplisit dalam format terstruktur. Pengambilan dilakukan menggunakan regex untuk mendeteksi pola seperti 'Fresh Graduate', 'minimal X tahun', atau 'X+ years of experience' dari teks deskripsi pekerjaan.

Ketiga, kolom salary_range terisi penuh secara teknis, namun sebagian besar nilainya adalah 'Disembunyikan' karena perusahaan di JobStreet memang tidak diwajibkan mencantumkan informasi gaji. Hal ini membatasi analisis salary hanya pada subset kecil data yang memiliki nilai numerik eksplisit.

3.3 Proses Pembersihan Data (Data Cleaning)

Proses pembersihan data dilakukan sepenuhnya menggunakan PySpark DataFrame API pada Cell 4 notebook. Terdapat empat langkah utama yang diterapkan:

Langkah	Operasi	Hasil
1. Null Handling	Nilai literal 'Tidak tersedia' diganti menjadi null menggunakan when/otherwise	Nilai missing terstandardisasi
2. Normalisasi job_type	regex extract untuk memetakan nilai ke kategori baku: Full time, Kontrak, Freelance	Kolom job_type konsisten
3. Ekstraksi salary_numeric	Regex untuk mengekstrak nilai numerik pertama dari salary_range, dikonversi ke DoubleType	Kolom baru: salary_numeric
4. Normalisasi posted_date	Regex untuk mengekstrak angka dari format relatif ('X jam yang lalu', 'X hari yang lalu')	Kolom baru: posted_days_ago

Tabel 3.2 Langkah-Langkah Proses Pembersihan Data

Setelah proses pembersihan, jumlah baris data tetap 150 baris dengan penambahan dua kolom baru (salary_numeric dan posted_days_ago), sehingga total menjadi 13 kolom.

Kolom	Null Sebelum Cleaning*	Null Sesudah Cleaning
job_title	0	0
company_name	0	0
location	0	0
job_type	0	0
experience_level	0	95
education_req	0	150
salary_range	0	115
job_requirements	0	0
job_responsibilities	0	115
posted_date	0	0
source_platform	0	0
salary_numeric	(kolom baru)	115
posted_days_ago	(kolom baru)	0

Tabel 3.3 Perbandingan Null Count Sebelum dan Sesudah Cleaning

Catatan: Sebelum cleaning, nilai missing disimpan sebagai literal 'Tidak tersedia' sehingga null count = 0. Setelah cleaning, literal tersebut dikonversi ke null yang sebenarnya.

3.4 Catatan Anomali: Kolom posted_days_ago


Hasil normalisasi kolom posted_date menghasilkan anomali yang perlu dicatat: seluruh 150 baris data terkategori sebagai 'kurang dari atau sama dengan 1 hari'. Hal ini disebabkan karena format yang dikembalikan halaman detail JobStreet adalah 'X jam yang lalu', bukan 'X hari yang lalu', sehingga nilai posted_days_ago untuk seluruh baris bernilai 0. Limitasi ini tidak mempengaruhi analisis lainnya dan menjadi catatan perbaikan untuk iterasi berikutnya.

BAB 4

ANALISIS EKSPLORATIF DATA (EDA)

Analisis eksploratif data dilakukan menggunakan Spark SQL setelah dataset yang telah dibersihkan didaftarkan sebagai temporary view bernama 'job_market'. Lima query SQL dijalankan untuk mengekstrak insight dari berbagai dimensi data.

4.1 Distribusi Geografis Lowongan



Gambar 1. Top 10 Kota dengan Jumlah Lowongan Data Science Terbanyak di Indonesia


Peringkat	Kota	Jumlah Lowongan	Persentase
1	Jakarta Raya	45	30.0%
2	Jakarta Selatan	20	13.3%
3	Indonesia*	20	13.3%
4	Jakarta Utara	10	6.7%
5	Kemayoran	10	6.7%
6	Cikarang Selatan	5	3.3%
7	Kebayoran Lama	5	3.3%
8	Malang	5	3.3%
9	Semarang	5	3.3%
10	Krian	5	3.3%

Tabel 4.1 Top 10 Kota dengan Lowongan Terbanyak

Catatan: Entri 'Indonesia' adalah nilai default platform JobStreet untuk lowongan remote atau tidak spesifik lokasi.

Jakarta Raya mendominasi distribusi geografis dengan 45 lowongan (30% dari total dataset), diikuti oleh Jakarta Selatan dan data berlabel 'Indonesia' masing-masing sebesar 20 lowongan (13.3%). Konsentrasi lowongan yang tinggi di kawasan Jakarta mencerminkan realita bahwa ekosistem teknologi dan startup Indonesia masih terpusat di ibu kota. Di luar Jabodetabek, kota Semarang dan Malang mulai menunjukkan permintaan terhadap talenta data.

4.2 Distribusi Tipe Pekerjaan




Gambar 2. Distribusi Tipe Pekerjaan pada Lowongan Data Science

Tipe Pekerjaan	Jumlah	Persentase
Full time	115	76.67%
Kontrak	30	20.00%
Freelance	5	3.33%
Total	150	100.00%

Tabel 4.2 Distribusi Tipe Pekerjaan

Dominasi posisi Full time (76.67%) mengindikasikan bahwa pasar kerja Data Science di Indonesia masih mengandalkan model karyawan tetap, selaras dengan karakteristik pekerjaan yang membutuhkan pemahaman mendalam terhadap data internal perusahaan dalam jangka panjang.

4.3 Perusahaan Paling Aktif Merekrut




Gambar 3. Top 10 Perusahaan dengan Jumlah Lowongan Terbanyak

Peringkat	Perusahaan	Jumlah Lowongan
1	Macquarie Group	20
2	PT ABISHAR TECHNOLOGIES INDONESIA	10
3	PT. Fidac Inovasi Technology	5
4	Ebit Co., Ltd	5
5	RemoHires	5
6	PT Nusa Satu Inti Artha	5
7	PT. DINETA JAYAA	5
8	PT Trans Antar Nusabird	5
9	PT PROSPECT MOTOR	5
10	PT. Frisidea Tech Indonesia	5

Tabel 4.3 Top 10 Perusahaan dengan Lowongan Terbanyak

Macquarie Group menempati posisi teratas dengan 20 lowongan, diikuti oleh PT Abishar Technologies Indonesia dengan 10 lowongan. Delapan perusahaan lainnya masing-masing memiliki 5 lowongan. Kehadiran Macquarie Group sebagai perusahaan jasa keuangan multinasional di posisi teratas mengindikasikan bahwa sektor keuangan merupakan salah satu industri dengan permintaan tinggi terhadap talenta data di Indonesia.

4.4 Distribusi Waktu Posting



Gambar 4. Distribusi Waktu Posting Lowongan

Rentang Posting	Jumlah Lowongan	Persentase
≤ 1 hari	150	100.00%

Tabel 4.4 Distribusi Waktu Posting

Catatan: Seluruh data terkategoriikan ≤ 1 hari karena anomali regex pada kolom `posted_date` (lihat Bab 3.4). Analisis distribusi waktu tidak menghasilkan variasi yang bermakna.

4.5 Analisis Gaji

Analisis salary hanya dapat dilakukan pada subset kecil data yang memiliki informasi gaji numerik eksplisit. Dari 150 lowongan, hanya 35 lowongan (23.3%) yang mencantumkan rentang gaji, dan dari jumlah tersebut hanya data dari 5 kota yang memiliki sampel cukup untuk dianalisis.

Kota	Jumlah Data	Rata-rata Gaji	Minimum	Maksimum
Jakarta Selatan	10	Rp 11.000.000	Rp 10.000.000	Rp 12.000.000
Jakarta Raya	10	Rp 3.750.000	Rp 500.000	Rp 7.000.000
Denpasar Selatan	5	Rp 3.300.000	Rp 3.300.000	Rp 3.300.000
Depok	5	Rp 3.000.000	Rp 3.000.000	Rp 3.000.000
Malang	5	Rp 500.000	Rp 500.000	Rp 500.000

Tabel 4.5 Rata-rata Salary per Kota

Catatan: Keterbatasan sampel yang sangat kecil (35 dari 150 baris) membuat kesimpulan dari analisis gaji ini tidak dapat digeneralisasi.

Jakarta Selatan menunjukkan rata-rata gaji tertinggi sebesar Rp 11.000.000 per bulan dengan rentang yang relatif sempit, mengindikasikan posisi-posisi dengan level senioritas yang serupa. Variasi gaji yang sangat lebar di Jakarta Raya (Rp 500.000 hingga Rp 7.000.000)

mencerminkan keberagaman jenis posisi yang ditawarkan, mulai dari posisi entry-level hingga senior.

BAB 5

MACHINE LEARNING: K-MEANS CLUSTERING

5.1 Pendekatan dan Motivasi

Algoritma K-Means Clustering dipilih sebagai metode machine learning utama pada proyek ini dengan pertimbangan bahwa tujuan analisis adalah menemukan pola pengelompokan alami dalam dataset tanpa label (unsupervised learning). Kolom `job_requirements` dipilih sebagai fitur utama karena merupakan kolom dengan kelengkapan tertinggi (100%) dan mengandung informasi paling kaya mengenai karakteristik setiap lowongan pekerjaan.

5.2 Pipeline Ekstraksi Fitur TF-IDF

Sebelum data teks dapat diproses oleh algoritma K-Means, diperlukan transformasi dari representasi teks menjadi representasi numerik. Pipeline yang digunakan terdiri dari tiga tahap yang diimplementasikan menggunakan PySpark MLlib:

Tahap	Transformasi	Parameter
1. Tokenisasi	Tokenizer: memecah kalimat menjadi daftar kata individual	<code>inputCol: job_requirements</code>
2. Penghapusan Stopwords	StopWordsRemover: menghapus kata-kata umum yang tidak bermakna secara analitis	Daftar stopwords kustom 60+ kata (Bahasa Indonesia)
3. TF-IDF	HashingTF + IDF: menghasilkan bobot numerik yang mencerminkan pentingnya sebuah kata dalam konteks dokumen	<code>numFeatures: 1000</code>

Tabel 5.1 Pipeline Ekstraksi Fitur TF-IDF

Term Frequency-Inverse Document Frequency (TF-IDF) dipilih karena metode ini mampu memberikan bobot lebih tinggi pada kata-kata yang spesifik terhadap suatu dokumen dibandingkan kata-kata yang umum muncul di seluruh dokumen. Dengan demikian, kata seperti 'Python' atau 'machine learning' akan mendapat bobot lebih tinggi daripada kata umum seperti 'bekerja' atau 'tim'.

5.3 Konfigurasi K-Means

Parameter	Nilai	Keterangan
<code>k</code> (jumlah cluster)	4	Ditentukan secara heuristik berdasarkan ekspektasi kategori posisi data science
<code>maxIter</code>	20	Jumlah iterasi maksimum konvergensi
<code>seed</code>	42	Untuk reproducibility hasil
Metrik Evaluasi	Silhouette	Menggunakan ClusteringEvaluator dari MLlib
<code>distanceMeasure</code>	euclidean	Default MLlib
<code>numFeatures</code> (TF)	1000	Dimensi ruang fitur HashingTF

Tabel 5.2 Konfigurasi K-Means

5.4 Hasil Clustering

Cluster	Jumlah	Persentase	Top 5 Keywords	Karakteristik Posisi
0	135	90.0%	data, business, support, requirements, system	Posisi umum Data Science dan Business Analyst
1	5	3.3%	artificial, intelligence, ai, tools, automasi	Spesialis Kecerdasan Buatan dan AI Engineering
2	5	3.3%	games, product, new, teams, ideas	Product Manager di industri game/teknologi
3	5	3.3%	will, quality, role, help, job	Quality Engineering dan kontrol kualitas
Total	150	100%	—	—

Tabel 5.3 Hasil K-Means Clustering ($k=4$, Silhouette Score: 0.1880)


5.5 Evaluasi: Silhouette Score

Silhouette Score yang diperoleh adalah 0.1880. Nilai ini berada pada rentang yang mengindikasikan pemisahan antar cluster yang lemah. Nilai Silhouette Score mendekati 1.0 menunjukkan cluster yang terpisah dengan baik, nilai mendekati 0 mengindikasikan cluster yang tumpang tindih, dan nilai negatif menunjukkan pengelompokan yang tidak tepat.

Nilai 0.1880 pada proyek ini dapat dijelaskan oleh dua faktor utama. Pertama, seluruh dataset berasal dari satu kategori pencarian ('Data Science'), sehingga vocabulary yang digunakan antar lowongan cenderung homogen. Kedua, distribusi cluster yang sangat timpang (90% data dalam satu cluster) secara matematis akan menghasilkan Silhouette Score yang rendah.

Perbaikan yang dapat dilakukan pada iterasi berikutnya meliputi pengujian berbagai nilai k menggunakan metode Elbow atau analisis Silhouette Score untuk berbagai k , penggunaan representasi fitur yang lebih canggih seperti Word2Vec atau document embeddings, serta perluasan dataset ke lebih banyak halaman dan kategori pekerjaan.

5.6 Visualisasi dan Interpretasi Cluster



WordCloud keseluruhan pada Gambar 6 memberikan gambaran komprehensif mengenai skills dan teknologi yang paling banyak diminta dalam lowongan Data Science di Indonesia. Kata 'data', 'business', 'project', 'AI', dan 'system' mendominasi, diikuti oleh teknologi spesifik seperti 'SQL', 'Excel', 'Microsoft', dan 'Google'. Kemunculan kata 'Bachelor' dan 'degree' mengkonfirmasi bahwa persyaratan pendidikan formal masih menjadi standar umum.

BAB 6

HASIL DAN PEMBAHASAN

6.1 Ringkasan Hasil Pipeline

Pipeline analitik yang dibangun berhasil menyelesaikan seluruh sembilan tahapan dari pengumpulan data hingga interpretasi hasil clustering. Berikut adalah ringkasan statistik akhir dari seluruh pipeline:

Metrik	Nilai
Total data awal (raw)	150 baris
Total data setelah cleaning	150 baris (tidak ada baris yang dihapus)
Total data untuk clustering	150 baris
Jumlah kolom asal	11 kolom
Jumlah kolom setelah cleaning	13 kolom (+salary_numeric, +posted_days_ago)
Algoritma clustering	K-Means (PySpark MLlib), k=4
Fitur clustering	TF-IDF dari job_requirements (1000 fitur)
Silhouette Score	0.1880
Versi PySpark	3.5.1
Versi Java	OpenJDK 17.0.19
File output dihasilkan	8 file (2 CSV + 5 PNG chart + 1 PNG wordcloud cluster)

Tabel 6.1 Ringkasan Statistik Akhir Pipeline

6.2 Insight Utama dari Analisis

Konsentrasi geografis: Pasar kerja Data Science di Indonesia masih sangat terpusat di Jakarta, dengan lebih dari 56% lowongan berasal dari wilayah Jakarta Raya dan Jakarta Selatan. Kota-kota lain seperti Semarang, Malang, dan Surabaya mulai menunjukkan permintaan namun masih sangat terbatas.

Dominasi Full-time: 76.7% lowongan bersifat full-time, menunjukkan bahwa perusahaan masih mengandalkan model karyawan tetap untuk posisi Data Science. Hanya 3.3% yang bersifat freelance, mengindikasikan bahwa pekerjaan berbasis proyek lepas belum menjadi norma di bidang ini.

Transparansi gaji rendah: Lebih dari 76.7% perusahaan tidak mencantumkan informasi gaji pada lowongan mereka. Ini merupakan pola yang umum di Indonesia namun menjadi hambatan bagi analisis kompensasi yang komprehensif.

Keragaman peran: Hasil clustering menunjukkan bahwa keyword 'Data Science' di JobStreet mencakup spektrum peran yang sangat luas, mulai dari Business Analyst, AI Engineer, Product Manager, hingga Quality Engineer.

Skills yang paling dibutuhkan: WordCloud menunjukkan bahwa kemampuan dalam SQL, komunikasi bisnis, pemahaman sistem, dan pengalaman dengan tools seperti Microsoft

Excel dan Google Workspace masih sangat relevan di samping kemampuan machine learning dan AI.

6.3 Keterbatasan Penelitian

Terdapat beberapa keterbatasan yang perlu diakui dalam proyek ini. Dari sisi pengumpulan data, keterbatasan pada 150 baris data dari lima halaman pencarian membuat dataset tidak dapat dianggap representatif secara statistik untuk seluruh pasar kerja Data Science di Indonesia. Platform JobStreet hanya mencerminkan sebagian dari keseluruhan pasar kerja dan tidak mencakup lowongan yang diposting secara langsung di website perusahaan atau platform lain seperti LinkedIn dan Glints.

Dari sisi kualitas data, tiga kolom memiliki kelengkapan yang sangat rendah (`education_req`: 0%, `job_responsibilities`: 23.3%, `experience_level`: 36.7%), yang membatasi kedalaman analisis yang dapat dilakukan. Selain itu, anomali pada kolom `posted_days_ago` yang seluruhnya bernilai sama menghasilkan analisis distribusi waktu posting yang tidak informatif.

Dari sisi pemodelan, Silhouette Score sebesar 0.1880 mengindikasikan bahwa kualitas clustering yang dihasilkan belum optimal. Parameter $k=4$ dipilih secara heuristik tanpa melalui proses optimasi formal menggunakan metode Elbow atau Grid Search. Representasi fitur TF-IDF, meskipun merupakan baseline yang baik, tidak mempertimbangkan konteks semantik antar kata.

BAB 7

KESIMPULAN DAN SARAN

7.1 Kesimpulan

Proyek ini berhasil membangun pipeline analitik big data end-to-end yang fungsional menggunakan Apache PySpark untuk menganalisis pasar kerja Data Science di Indonesia berdasarkan data yang dikumpulkan dari platform JobStreet. Seluruh sembilan tahapan pipeline berhasil dieksekusi, mulai dari pengumpulan data otomatis menggunakan Selenium hingga penerapan K-Means Clustering dari MLlib.

Secara substantif, analisis menunjukkan bahwa pasar kerja Data Science di Indonesia masih sangat terpusat di Jakarta dengan dominasi posisi full-time. Skills berbasis SQL, komunikasi bisnis, dan pemahaman sistem menjadi kompetensi yang paling banyak diminta. Pengelompokan dengan K-Means mengidentifikasi empat segmen pasar: posisi Data Science umum, spesialis AI, product management, dan quality engineering, meskipun distribusi yang tidak merata mencerminkan homogenitas dataset.

Dari perspektif teknis, proyek ini mendemonstrasikan kemampuan PySpark dalam menangani seluruh tahapan pipeline big data dalam satu ekosistem, dari Spark SQL untuk analisis eksploratif hingga MLlib untuk machine learning, tanpa perlu berpindah ke framework lain.

7.2 Saran untuk Pengembangan

1. Memperluas dataset ke lebih banyak halaman (minimal 20 halaman) dan mencakup platform lain seperti Glints dan LinkedIn untuk meningkatkan representativitas analisis.
2. Mengimplementasikan optimasi parameter k menggunakan metode Elbow dan Silhouette Analysis untuk berbagai nilai k guna menemukan jumlah cluster yang paling optimal.
3. Mengganti representasi TF-IDF dengan embedding berbasis model bahasa (seperti Word2Vec atau FastText) untuk menangkap hubungan semantik antar kata dengan lebih baik.
4. Memperbaiki proses ekstraksi atribut education_req dan posted_date untuk meningkatkan kelengkapan dataset.
5. Menambahkan analisis time-series untuk melacak perubahan tren pasar kerja Data Science dari waktu ke waktu.

Laporan ini disusun sebagai dokumentasi final project mata kuliah Analitik Big Data, Departemen Teknik Informatika, Fakultas Ilmu Komputer, Universitas Brawijaya, 2026.